斯坦福大学 · ICME 课程 · 推理模型专题

DeepSeek-R1 为什么会推理?

AI 不是只靠预测下一个 Token ——
它是在强化学习里被训练出来的。

源片：BV1BQsX6yELJ（942.0s）· 斯坦福讲座 · B 站搬运版

讲稿提炼 · 16 页 · 事实只取自本片

2026-11-12 制作

术语 · 先把话说清楚

推理 = 解决问题的能力

不是推理

“斯坦福 Transformers 与 LLM 课程的课程代码是什么？”

查得到 / 查不到。

你不需要自己想一步。

是推理

“这只熊 2020 年出生，现在几岁了？”

答案要靠“现在的年份 − 出生的年份”

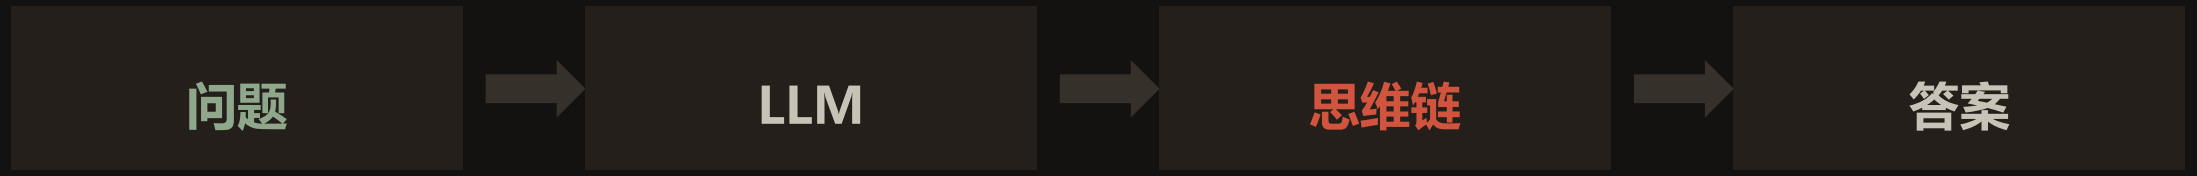
这一步算出来。

同一个模型，两类问题。区别不在模型，在题目要不要模型自己想一步。

核心想法 · 2024 年之前

教模型先解释推理，再给答案

这就是 Chain of Thought（思维链）。



当时的做法

每次都在提示里要求它输出思维链。

好处是能拿到理由；

坏处是得写进提示、还得被模型忽略。

真正的目标

让模型自己决定输出思维链，

而不是每次都靠提示去求。

—— 这一步是后面所有事的前提。

时间线 · 推理模型从 2024 秋开始普及

六个月，从一个预览到人人默认

2024-09-12
OpenAI
o1-preview 首次发布

2024-12-19
Google
Gemini 2.0 Flash Thinking

2025-01-20
DeepSeek
R1 开放权重 + 技术报告

2025-02-19
xAI
Grok 3 Beta

2025-02-24
Anthropic
Claude 3.7 Sonnet

R1 的特别之处：不是第一个推理模型，是第一个把方法与权重一起开源的。

幻灯片原文注明这条时间线“仅供示意，并不完整”。

来源：斯坦福讲座幻灯片「Reasoning models started trending in 2024-2025」

2025 年的标志 · 藏在界面里

推理模型开始把思考过程摆到台面上

讲座给的判据不是榜单，是界面上的三样东西。

Thinking

模型名旁的标签，
回答上方的「思考 5 秒」

Thought summary

给出一段思考摘要，
不是原始完整思维链

思考档位

可调的推理强度，
从低到高决定算力

到 2026 年，界面换成更直白的说法：ChatGPT 5.6 Sol 给出「5 岁或 6 岁」，
并把推理强度开到 Extra High。

截图日期：2025-11-03（ChatGPT 5 Thinking）· 2026-10-06（ChatGPT 5.6 Sol）

范式 · 请求的形状变了

答案后面多了一段链

直到 2024

问题 → LLM → 答案

推理模型

问题 → LLM → **思维链** → 答案

接口层的对应变化

OpenAI、Anthropic、Google 的 API 都加了推理强度参数，

价格按思考量分档。

代价

想得多就烧得多。

思考 token 从“免费副产品”变成要计费的主项。

矛盾 · 为什么要藏

思维链很有用，所以厂商开始收起来

讲座提到一篇报道：第三方供应商能通过 API 拿到完整思维链。

安全

完整思维链会带出用户对话里

没打算公开的前提与信息

护城河

高质量思维链能改进别人的模型，

不藏起来等于替对手做数据

结果：现在你能拿到的是「思考摘要」，不是「完整思维链」。

推理过程从可复制的能力，变成了不可迁移的资产。

题目、答案、可验证性

关键：这类题不需要人打分，答案能自动判对错 —— 这才让强化学习能训。

题目

数学：熊 2020 年生，
现在几岁？

编码：比最大那只熊小的
最大一只

答案

2026 − 2020 = 6

```
def second_biggest_bear(bears):
    largest = max(bears)
    return max(b for b in bears
               if b < largest)
```

验证

答案：比 ground truth

解法：跑测试用例
#1 #2 #3 全部通过

来源：斯坦福讲座幻灯片「Reasoning-based benchmarks」

Group Relative Policy Optimization

组内相对优势：用同一道题的多个回答互相比较，而不是用一个打分器。

1 采样

同一个提示

让模型生成一组回答

2 判对错

每条回答对照

ground truth

3 算优势

组内相对比较：

这条比同组好多少

4 更新

好的多练，差的少练

（带 KL 约束）

关键简化：不需要单独的 value model 去估“这一步有多好”。

直接拿模型的回答和标准答案比 —— 这就是 GRPO 省下来的那一大块工程。

证据 · 推理能力是 RL 训出来的

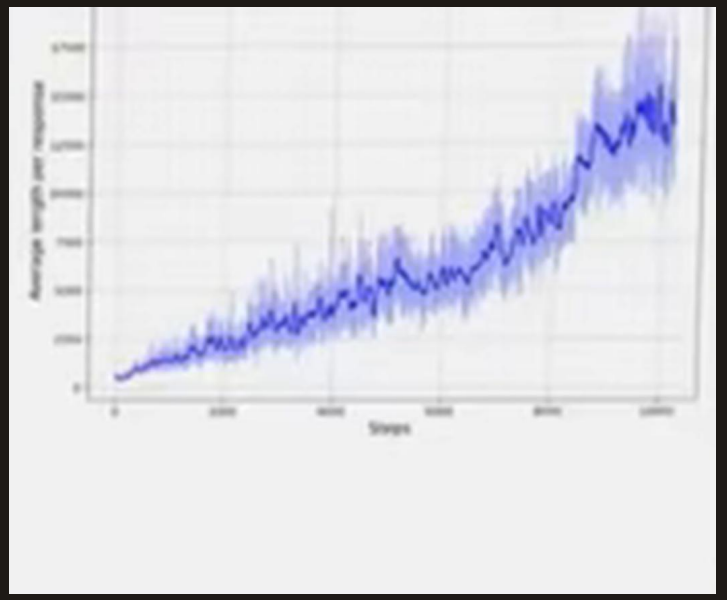
准确率在爬升，回答长度在爆炸



AIME 准确率（读图值）

pass@1 约 0.05 → 0.71

cum@16 约 0.25 → 0.87；o1 参考线约 0.83



平均回答长度（读图值）

约 200 → 15,000–20,000 token

横轴 1 万步

图：DeepSeek-R1 论文（斯坦福讲座引用）；数值为从图中读出的近似值

限制 · 一

奖励太粗：整条回答只记一次分

Outcome reward

回答整条正确 → 奖励

回答整条错误 → 没有奖励

中间没有梯度

后果

一题对错就决定整段的去留。

样本效率低，训练不稳。

于是有了第二个问题：奖励信号是从哪来的？

来源：斯坦福讲座转写稿「你会获得一个非常浓厚的奖励……整个出口正确还是不正确」

信号从哪来：Off-policy 还是 On-policy

Off-policy

观测不是模型生成的

信号密集（dense）

例：每一步都有 shaping 奖励

问题：模型只学会在别人的路上走对，

自己的路上不会走。

On-policy

观测由模型自己生成

信号稀疏（sparse）

例：GRPO 只在整条回答上给信号

问题：稀疏，样本效率低。

2026 年的新方法要同时拿到两个好处：走自己的路，又拿到密集信号。

新方法 · 一

On-policy Distillation

用更强的模型，对学生模型的每一个 token 给出预测，学生照着调整。

它解决了什么

轨迹是学生自己走的 → on-policy

每个 token 都有对照 → 密集信号

怎么对齐

每生成一个 token，问一次教师：

你会怎么预测？

比较两者，把差距当作损失。

一句话：off-policy 的信号密度 + on-policy 的轨迹来源，两个都要。

新方法 · 二

没有教师的时候：Self-distillation

学生提示

题目：求 $f(x)=3x^2-5x-1$ 在 $x=2$ 处的导数。

只给题目，不给答案。

教师提示

同一道题，外加一句：

“这是 $x=2$ 处的参考解 $f'(x)=6x-5=7$，请给出你自己的解法。”

答案：7

教师就是同一个模型，只是被喂了参考答案；讲座说这是目前用得最多的做法。

新方法 · 三

把专科老师请进来：Multi-teacher

Step 1

SFT

通用指令数据

做基础对齐

Step 2

领域专项训练

数学 / 指令 / 软件

逻辑 / 安全

分别训出专科学生

Step 3

MPDO

多个教师模型协同

生成、重写、蒸馏

和 DeepSeek-R1 论文的做法对上：先冷启动做专项能力，再用 on-policy 蒸馏把老师的能力收进一个模型。

来源：斯坦福讲座幻灯片「Multi-teacher on-policy distillation」

四个该问但没问的问题

GRPO 到底省了多少

省掉 value model 是真的，

但换来的样本效率损失有多少，讲座没量化。

涌现的复现门槛

RL 训出推理能力需要多少算力、

多少次失败尝试？没有可复现的账。

蒸馏之后还是涌现吗

能力被蒸馏过来之后，

“多想”还是自己长出来的吗？

这些数字还成立吗

幻灯片数据来自 2025 年初的 R1-Zero，

今天的模型基线已经完全不同。

来源：斯坦福大学 ICME 课程《Transformers & Large Language Models》推理专题（2026）；

B 站搬运版 BV1BQsX6yELJ 转写。引用论文：DeepSeek-R1 (DeepSeek-AI, 2025)。