

Bilibili AI 公开赛

我用 Kimi K3 实现了 跟 "峰哥" 实时视 频通话

Real-time Video Call with "Fengge" - powered by Kimi K3 + VoxEMW

六块积木本地部署，一块 4090 显卡搞定。VibeCoding 全程实战。

UP 主：电磁波 Studio | 2026-07-30 | BV1En3b6rEuR

02:36

Demo duration

11.4 万

播放量

2,701

点赞

2,620

收藏

1,822

转发

VibeCoding / VoxEMW / Six Building
Blocks

创作者与系列背景



电磁波 Studio

大学计算机教师 / VibeCoding
玩家

Bilibili

B 站个人空间 : space.bilibili.com/492428186

系列作品 : VoxEMW 开发日记 (5 期)

VibeCoding

VoxEMW

Kimi K3

Deep

单期最高播放量


11.4 万

views / 2,701 likes / 2,620 favorites / 1,822 shares

VoxEMW 是一条五期的开发日记

从 3090 显卡的 "良子" 语音系统, 到良子 x 峰哥唠嗑, 再到斗地主游戏, 语音播报大屏幕, 最后是本期的实时视频通话 -- 五块积木一块块拼起来, 才有了这一通电话.

跟 AI "峰哥" 实时视频通话



AI 峰哥 金句（节选）

Q 峰哥，你是怎么得出世间万物一切都是好事？

A 这世界就是个辩证法，你看着是坏事，换个角度它就是好事。

被公司开了，好事啊 -- 终于不用伺候那个 [哔] 领导了。


被对象 [哔]，好事啊 -- 帮你提前排了雷，省得以后戴 [哔] 帽子。

登山爬最陡的坡，翻过去之后风景那叫一个绝。

人设蒸馏后，峰哥的口吻被完美复刻。

VoxEMW 框架：六块积木搭起实时视频通话

VibeCoding 全程，一块 4090 显卡本地部署，串起 " 听 / 懂 / 答 / 演 " 四步。



听 -> VAD -> ASR 懂 -> LLM + 人设蒸馏 答 -> TTS 音色迁移 演 -> 对口型

听 + 懂：语音入口与对话生成

01

听

VAD

语音活动检测

判断用户什么时候说完了话，决定何时触发 ASR。没有它，实时对话会出现“抢话”和“截断”。

实现 / 案例

常见实现：Silero VAD / webrtcvad / pyannote

- * 音频流实时检测
- * 端点检测，避免噪声触发
- * 降低下游 ASR 负载

02

听

Qwen3-ASR-1.7B

语音识别

把用户的语音转成文字。1.7B 体量，在 4090 上推理速度可观，中文识别率有保障。

实现 / 案例

阿里 Qwen 团队 ASR 系列，开源权重

- * 17 亿参数
- * 中英混合识别
- * 输出文本 -> 喂给 LLM

03

懂

DeepSeek-V4-Flash

对话大模型

负责回答问题，串联上下文。配合女娲 skill 蒸馏的峰哥人设，还原峰哥的口吻与思维方式。

实现 / 案例

DeepSeek 团队 V4 正式版，Flash 档位

- * Flash 档位，延迟低
- * 接住峰哥人设 prompt
- * 输出待合成文本

懂 + 答 + 演：人设蒸馏 / 音色 / 口型

人设 + 音色 + 口型 -- 让模型不止 " 答得对 ", 还要 " 长得像 / 说得像 "。

04

答

VoxCPM2

音色迁移合成 TTS

干两件事：把峰哥的音色抽出来，再用这个音色合成最终语音。输出 wav 给下一棒对口型。

实现 / 案例

OpenBMB VoxCPM 系列，本地推理

- * 音色 clone 一次
- * 推理时直接合成
- * 输出 wav 实时流

05

懂

人设skill

人设风格提炼

把峰哥的思维方式 / 口头禅 / 段子都蒸馏出来，喂给 DeepSeek。这样 LLM 才能用峰哥的口吻说话。

实现 / 案例

up 主自研 skill，嵌入 prompt

- * 分析语料，提炼人设
- * 生成 system prompt
- * 与 LLM 解耦

06

演

SoulX-FlashHead

实时对口型驱动

今天的绝对主角。根据 TTS 输出的语音，实时驱动虚拟人物的口型和表情，让 " 视频通话 " 看起来像真人在说话。

实现 / 案例

SoulX 系列，直播级实时推理

- * 音频 -> 口型参数
- * 驱动虚拟人脸
- * 延迟需 < 200ms

为什么这条视频值得 11.4 万人看

6

块积木

VoxEMW 框架

VAD + ASR + LLM + TTS +
人设蒸馏 + 对口型, 一条流水
线串起实时视频通话.

1

块 4090

本地部署

不需要云端, 一块消费级显卡
跑全栈. VAD / ASR / TTS /
对口型全部本地推理.

100%

VibeCoding

全程 AI 写码

UP 主只需要把需求讲清楚,
剩下的活全是 Kimi K3 干的.
一句话开始, 应用就出来了.

OSS

Open Source

MIT 协议开源

VoxEMW 完整代码已开源到
GitHub:
github.com/emwstudio/VoxEMW, fork 就能本地跑.

核心 takeaway: 实时视频通话的 "端到端本地化", 已经从 "实验室 demo" 走到 "UP 主 2 天可复刻".

Takeaways

三条看完就想动手的启示

01

VibeCoding 已经 " 开箱即用 "

Kimi K3 这类代码大模型，配合 MCP / 工具链，已经能独立完成一个完整应用的搭建。UP 主口述需求，模型自己接 ASR / TTS / 对口型。

02

积木式拼装，不再是 " 造轮子 "

VAD / ASR / LLM / TTS / 人设蒸馏 / 对口型，每一块都有现成开源方案。把它们接好，就是一个新应用。思路远比代码重要。

03

人设蒸馏是 IP 复活的关键

" 峰哥 " 这类 B 站 UP 主的人设，通过女娲 skill 蒸馏出思维方式 / 口头禅，再让 LLM 用他的口吻回应。复活一个 IP，比想象中简单。
